



# **Diseño de Atributos desde Serie de Tiempo + Red Neurona Superficial (SNN).**

**Prof. NIBALDO RODRÍGUEZ A.**



## Descomposición de Series de Tiempo (ST)

- Sea  $X$  una serie de tiempo discreta de longitud  $N$ , dado por:

$$X = \{x_n\}_{n=1}^N$$

$$X = \{x_1, x_2, \dots, x_L, \dots, x_K, \dots, x_N\}$$

- Descomposición en  $L$ -componentes intrínsecos desde una ST:

$$X = \sum_{i=1}^L C_i$$



## Algoritmo de Extracción de Componentes desde ST:

- Paso #1: Construir Matriz de Hankel.
- Paso #2: SVD de Matriz Hankel.
- Paso #3: Calcular Componentes.



## Matriz de Hankel:

$$X = \{x_1, x_2, \dots, x_L, \dots, x_K, \dots, x_N\}$$

$$H = \begin{pmatrix} x_1 & x_2 & x_3 & x_4 & \dots & x_K \\ x_2 & x_3 & x_4 & x_5 & \dots & x_{K+1} \\ x_3 & x_4 & x_5 & x_6 & \dots & x_{K+2} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_L & x_{L+1} & x_{L+2} & \dots & \dots & x_N \end{pmatrix}$$

$$K = N - L + 1$$

# MATRIZ HANKEL

$$X = \{x_1, x_2, \dots, x_N\}$$

$$H = \begin{pmatrix} x_1 & x_2 & x_3 & x_4 & \dots & x_K \\ x_2 & x_3 & x_4 & x_5 & \dots & x_{K+1} \\ x_3 & x_4 & x_5 & x_6 & \dots & x_{K+2} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_L & x_{L+1} & x_{L+2} & \dots & \dots & x_N \end{pmatrix}$$

## Ejemplo: MATRIZ HANKEL

$$X = \{x_n\}_{n=1}^N, N = 12$$

$$X = \{1, 2, 3, \dots, 10, 11, 12\}$$

$$L = 5$$

$$H = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 \\ 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 \\ 4 & 5 & 6 & 7 & 8 & 9 & 10 & 11 \\ 5 & 6 & 7 & 8 & 9 & 10 & 11 & 12 \end{pmatrix}$$



## Extracción de Componentes usando H-SVD:

- Paso #1: Calcular matriz Hankel: L-filas por K-columna

$$H = \text{matriz}(L, K)$$

- Paso #2: Descomposición de valores singular de Hankel :

$$H = U \times S \times V^T, \text{ donde}$$

$$H = H_1 + H_2 + \dots, H_L$$



## Extracción de Componentes usando H-SVD

- Paso #3: Calcular componentes de Hankel:

$$\begin{aligned} H_i &= s(i) \times U(:, i) \times V(:, i)^T, \\ i &= 1, 2, \dots, L, \\ s &= \text{diag}(S) \end{aligned}$$



## Extracción de Componentes usando H-SVD

- Paso #3: Calcular componentes de Hankel:

$$H_i = \begin{pmatrix} x_1^i & x_2^i & x_3^i & x_4^i & \dots & x_K^i \\ x_2^i & x_3^i & x_4^i & x_5^i & \dots & x_{K+1}^i \\ x_3^i & x_4^i & x_5^i & x_6^i & \dots & x_{K+2}^i \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_L^i & x_{L+1}^i & x_{L+2}^i & \dots & \dots & x_N^i \end{pmatrix}$$

$$C_i = [x_1^i \quad x_2^i \quad \dots \quad x_K^i \quad x_{K+1}^i \quad \dots \quad x_N^i]$$
$$i = 1, \dots, L$$

**Componente  $i$ -th de Hankel**



## Ejemplo: H-SVD

$$X = [1.2371 \quad 0.1797 \quad 0.0042 \quad 1.5944 \quad 0.7729 \quad 1.0414 \quad 0.0035]$$

$$L - row = 3$$

$$H = \begin{bmatrix} 1.2371 & 0.1797 & 0.0042 & 1.5944 & 0.7729 \\ 0.1797 & 0.0042 & 1.5944 & 0.7729 & 1.0414 \\ 0.0042 & 1.5944 & 0.7729 & 1.0414 & 0.0035 \end{bmatrix}$$



## Ejemplo: H-SVD

$$U = \begin{bmatrix} -0.6100 & 0.6912 & 0.3875 \\ -0.5762 & -0.0512 & -0.8157 \\ -0.5439 & -0.7209 & 0.4295 \end{bmatrix}$$

$$sv = [2.9308 \quad 1.5786 \quad 1.4493]$$

$$V = \begin{bmatrix} -0.2936 & 0.5339 & 0.2309 \\ -0.3341 & -0.6495 & 0.5182 \\ -0.4578 & -0.4028 & -0.6671 \\ -0.6771 & 0.1975 & 0.2999 \\ -0.3663 & 0.3030 & -0.3784 \end{bmatrix}$$



## Ejemplo: H-SVD

$$H_1 = \begin{bmatrix} 0.5249 & 0.5974 & 0.8184 & 1.2105 & 0.6548 \\ 0.4958 & 0.5643 & 0.7731 & 1.1434 & 0.6185 \\ 0.4680 & 0.5327 & 0.7298 & 1.0794 & 0.5839 \end{bmatrix}$$

$$C_1 = [0.5249 \quad 0.5974 \quad 0.8184 \quad 1.2105 \quad 0.6548 \quad 0.6185 \quad 0.5839]$$



## Ejemplo: H-SVD

$$H_2 = \begin{bmatrix} 0.5825 & -0.7087 & -0.4395 & 0.2155 & 0.3307 \\ -0.0432 & 0.0525 & 0.0326 & -0.0160 & -0.0245 \\ -0.6075 & 0.7391 & 0.4584 & -0.2247 & -0.3448 \end{bmatrix}$$

$$C_2 = [0.5825 \quad -0.7087 \quad -0.4395 \quad 0.2155 \quad 0.3307 \quad -0.0245 \quad -0.3448]$$



## Ejemplo: H-SVD

$$H_3 = \begin{bmatrix} 0.1297 & 0.2910 & -0.3747 & 0.1684 & -0.2125 \\ -0.2730 & -0.6126 & 0.7887 & -0.3546 & 0.4473 \\ 0.1437 & 0.3226 & -0.4153 & 0.1867 & -0.2356 \end{bmatrix}$$

$$C_3 = [0.1297 \quad 0.2910 \quad -0.3747 \quad 0.1684 \quad -0.2125 \quad 0.4473 \quad -0.2356]$$




## Ejemplo: H-SVD

$$C_1 = [0.5249 \quad 0.5974 \quad 0.8184 \quad 1.2105 \quad 0.6548 \quad 0.6185 \quad 0.5839]$$

$$C_2 = [0.5825 \quad -0.7087 \quad -0.4395 \quad 0.2155 \quad 0.3307 \quad -0.0245 \quad -0.3448]$$

$$C_3 = [0.1297 \quad 0.2910 \quad -0.3747 \quad 0.1684 \quad -0.2125 \quad 0.4473 \quad -0.2356]$$

$$X = C_1 + C_2 + C_3$$



# **Series de tiempo:**

## **Descomposición Diádica:**

**Prof. NIBALDO RODRÍGUEZ A.**



## Descomposición Diádica

- Considere una serie de tiempo discreta :  $\mathbf{X} = \{x_n\}_{n=1}^N$

**Matriz de Hankel:**

$$H = \begin{pmatrix} x_1 & x_2 & x_3 & \dots & x_{N-1} \\ x_2 & x_3 & x_4 & \dots & x_N \end{pmatrix}$$

**Descomposición diádica:**

$$[U \ S \ V] = SVD(H) \\ s = \text{diag}(S)$$

**Hankelización:**

$$H_1 = s(1) \times U(:,1) \times V(:,1)^T \\ H_2 = s(2) \times U(:,2) \times V(:,2)^T$$



## Descomposición Diádica

- Componentes Diádicos:

$$H_1 = \begin{pmatrix} x_1^1 & x_2^1 & x_3^1 & \dots & x_{N-1}^1 \\ x_2^1 & x_3^1 & x_4^1 & \dots & x_N^1 \end{pmatrix}$$

$$C_1 = \begin{bmatrix} x_1^1 & \bar{x}_2^1 & \bar{x}_3^1 & \dots & \bar{x}_{N-1}^1 & x_N^1 \end{bmatrix}$$



## Descomposición Diádica

- Componentes Diádicos:

$$H_2 = \begin{pmatrix} x_1^2 & x_2^2 & x_3^2 & \dots & x_{N-1}^2 \\ x_2^2 & x_3^2 & x_4^2 & \dots & x_N^2 \end{pmatrix}$$

$$C_2 = \begin{bmatrix} x_1^2 & \bar{x}_2^2 & \bar{x}_3^2 & \dots & \bar{x}_{N-1}^2 & x_N^2 \end{bmatrix}$$

$$X = C_1 + C_2$$

## Ejemplo: Descomposición Diádica

- Sea  $x = \{1, 2, \dots, 7\}$

$$H = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix}$$

- Descomposición Diádica:  $[U \ S \ V] = SVD(H)$

$$V = \begin{bmatrix} -0.1442 & 0.7092 \\ -0.2370 & 0.4890 \\ -0.3298 & 0.2687 \\ -0.4226 & 0.0484 \\ -0.5154 & -0.1719 \\ -0.6083 & -0.3922 \end{bmatrix}$$

$$U = \begin{bmatrix} -0.6287 & -0.7777 \\ -0.7777 & 0.6287 \end{bmatrix}$$

$$s = \text{diag}(S) = [15.1507 \ 0.6763]$$



## Ejemplo: Descomposición Diádica

- Hankelización:

$$H_1 = s(1) \times U(:,1) \times V(:,1)^T$$

$$H_1 = \begin{bmatrix} 1.3730 & 2.2572 & 3.1413 & 4.0254 & 4.9096 & 5.7937 \\ 1.6984 & 2.7921 & 3.8858 & 4.9794 & 6.0731 & 7.1668 \end{bmatrix}$$

- Componentes Diádicos::

$$C_1 = [1.3730 \quad 1.9778 \quad 2.9667 \quad 3.9556 \quad 4.9445 \quad 5.9334 \quad 7.1668]$$



## Ejemplo: Descomposición Diádica

- Hankelización:


$$H_2 = s(2) \times U(:,2) \times V(:,2)^T$$

$$H_2 = \begin{bmatrix} -0.3730 & -0.2572 & -0.1413 & -0.0254 & 0.0904 & 0.2063 \\ 0.3016 & 0.2079 & 0.1142 & 0.0206 & -0.0731 & -0.1668 \end{bmatrix}$$

- Componentes Diádicos::

$$C_2 = [-0.3730 \quad 0.0222 \quad 0.0333 \quad 0.0444 \quad 0.0555 \quad 0.0666 \quad -0.1668]$$

$$x = C_1 + C_2$$




# **Series de tiempo:**

## **Descomposición Multi-escala Diádica usando Hankel**

Prof. NIBALDO RODRÍGUEZ A.

# Descomposición Multi-escala







## Ejemplo: Descomposición Multi-scale

- Sea  $x = \{1, 2, \dots, 8\}$

$$H = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \\ 2 & 3 & 4 & 5 & 6 & 7 & 8 \end{bmatrix}$$

- Nivel #1:

$$C_{1,1} = [1.7448 \ 1.1712 \ 1.0361 \ 1.0806 \ 0.7769 \ 0.7084 \ 0.7606 \ 0.6123]$$

$$C_{1,2} = [0.233 \ -0.225 \ -0.076 \ 0.313 \ -0.123 \ -0.208 \ 0.5145 \ -0.594]$$



## Ejemplo: Descomposición Multi-scale

- Sea  $x = \{1, 2, \dots, 8\}$

$$H = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \\ 2 & 3 & 4 & 5 & 6 & 7 & 8 \end{bmatrix}$$


- Nivel #2:

$$C = \begin{bmatrix} 1.61 & 1.26 & 1.07 & 0.98 & 0.82 & 0.73 & 0.70 & 0.6200 \\ 0.12 & -0.09 & -0.03 & 0.09 & -0.05 & -0.02 & 0.05 & -0.0077 \\ 0.19 & -0.15 & -0.05 & 0.20 & -0.08 & -0.19 & 0.44 & -0.6308 \\ 0.04 & -0.07 & -0.01 & 0.10 & -0.03 & -0.01 & 0.06 & 0.0360 \end{bmatrix}$$

## Ejemplo: Descomposición Multi-scale

- Nivel #3:

$$C = \begin{bmatrix} 1.56 & 1.296 & 1.091 & 0.960 & 0.837 & 0.744 & 0.686 & 0.608 \\ 0.05 & -0.029 & -0.021 & 0.024 & -0.009 & -0.012 & 0.0187 & 0.0123 \\ 0.14 & -0.07 & -0.017 & 0.067 & -0.042 & -0.013 & 0.0351 & -0.028 \\ -0.007 & -0.027 & -0.017 & 0.029 & -0.009 & -0.010 & 0.021 & 0.020 \\ 0.125 & -0.105 & -0.042 & 0.136 & -0.045 & -0.181 & 0.414 & -0.649 \\ 0.06 & -0.04 & -0.017 & 0.069 & -0.042 & -0.0161 & 0.0355 & 0.0184 \\ 0.06 & -0.04 & -0.017 & 0.068 & -0.043 & -0.0126 & 0.0264 & -0.0155 \\ -0.01 & -0.03 & -0.0002 & 0.041 & 0.006 & 0.0017 & 0.0390 & 0.0515 \end{bmatrix}$$



# **Cuantificación de la Información**



## Entropía de Shannon

- Permite medir el contenido de información de un conjunto de datos.
- Permite medir la Incertidumbre de un conjunto de datos.

$$\text{Sea } X = \{x_1, x_2, \dots, x_N\}$$

$$H(X) = - \sum_{i=1}^N P(x_i) \log_2(P(x_i))$$

$$H(X) = - \frac{1}{\log_2(N)} \sum_{i=1}^N P(x_i) \log_2(P(x_i))$$

**Entropía Normalizada**




## Ejemplo: Entropía de Shannon

- Sea un conjunto de eventos  $X=\{x_1, x_2\}$ , donde:

$$\begin{aligned}P(x_1) &= a, & a &\in [0,1] \\P(x_2) &= 1 - a\end{aligned}$$

$$H(X) = -\{P(x_1) \log_2(P(x_1)) + P(x_2) \log_2(P(x_2))\}$$

## Ejemplo: Entropía de Shannon



- A mayor Entropía menos Información



# **Entropía Espectral de Shannon:**

## **Transformada de Fourier**

Prof. NIBALDO RODRÍGUEZ A.





## Transformada de Fourier continua

- Transformada de Fourier Continua (CFT):

$$F(f) = \int_{-\infty}^{\infty} x(t) e^{-j 2 \pi f t} dt$$
$$j = \sqrt{-1}$$

- Transformada de Fourier continua Inversa (ICFT):

$$x(t) = \int_{-\infty}^{\infty} F(f) e^{j 2 \pi f t} df$$

- $t$ : denota el tiempo de la señal,  $f$ : representa la frecuencia de Fourier



## Descomposición de Fourier

- Transformada de Fourier Discreta (DFT):

$$F(k) = \frac{1}{N} \sum_{n=0}^{N-1} x(n) \exp \left( -j \frac{2\pi}{N} kn \right)$$
$$k = 0, 1, \dots, N-1, \quad j = \sqrt{-1}$$

- Transformada de Fourier Inversa Discreta (IDFT):

$$x(n) = N \times \sum_{k=0}^{N-1} F(k) \exp \left( j \frac{2\pi}{N} kn \right)$$
$$n = 0, 1, \dots, N-1$$

- $N$ : número de muestras de la serie de tiempo,  $k$ :  $k$ -th línea de frecuencia de Fourier.



## Espectro de Fourier

$$F(k) = A(k) \times \exp(j\Phi(k))$$

$$F(k) = a_k + jb_k$$

$$A(k) = \sqrt{a_k^2 + b_k^2}$$

$$k = 0, 1, 2, \dots, N - 1$$



## Ejemplo: FT de Función Coseno

$$f(t) = \cos(2\pi \times f_0 \times t)$$
$$f(t) = \frac{1}{2} [e^{j2\pi f_0 t} + e^{-j2\pi f_0 t}]$$

$$F(f) = \int_{-\infty}^{\infty} f(t) e^{-j2\pi f t} dt$$

$$F(f) = \frac{1}{2} \int_{-\infty}^{\infty} e^{-j2\pi(f-f_0)t} dt + \frac{1}{2} \int_{-\infty}^{\infty} e^{-j2\pi(f+f_0)t} dt$$

$$F(f) = \frac{1}{2} [\delta(f - f_0) + \delta(f + f_0)]$$

$$\delta(x) = \begin{cases} 1 & x = 0 \\ 0 & x \neq 0 \end{cases}$$



## Ejemplo: FT de Función Seno

$$f(t) = \sin(2\pi \times f_0 \times t)$$
$$f(t) = \frac{1}{2j} \left[ e^{j2\pi f_0 t} - e^{-j2\pi f_0 t} \right]$$

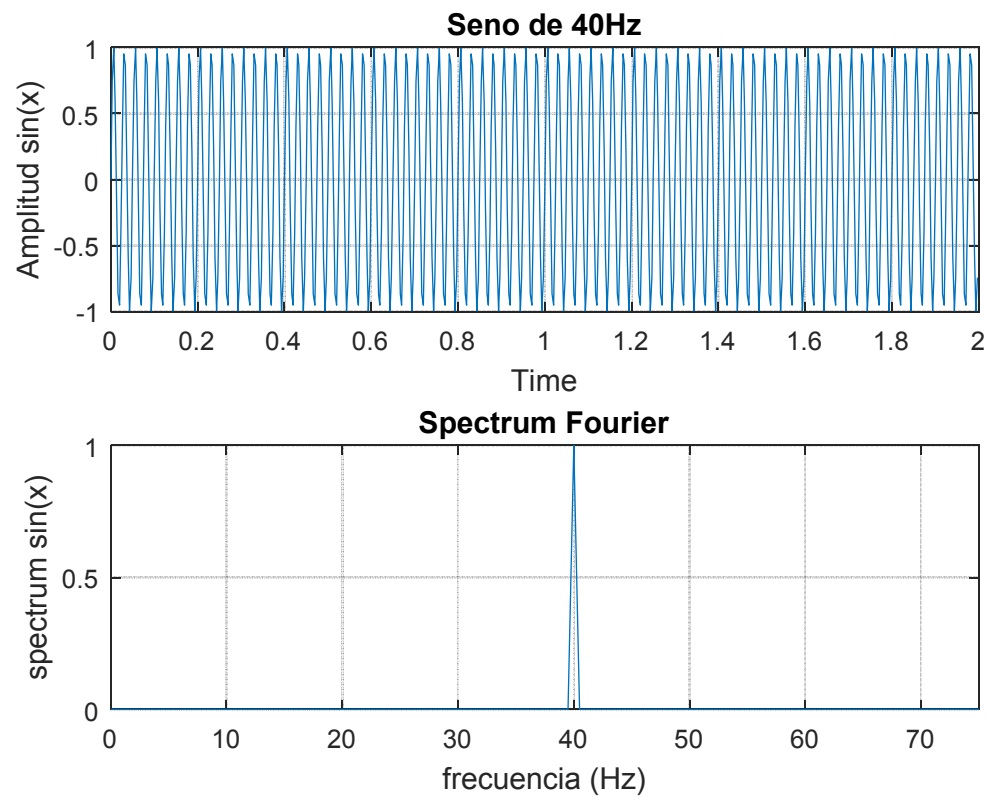
$$F(f) = \int_{-\infty}^{\infty} f(t) e^{-j2\pi f t} dt$$

$$F(f) = \frac{1}{2j} \int_{-\infty}^{\infty} e^{-j2\pi(f-f_0)t} dt - \frac{1}{2j} \int_{-\infty}^{\infty} e^{-j2\pi(f+f_0)t} dt$$

$$F(f) = -\frac{j}{2} \delta(f - f_0) + \frac{j}{2} \delta(f + f_0)$$

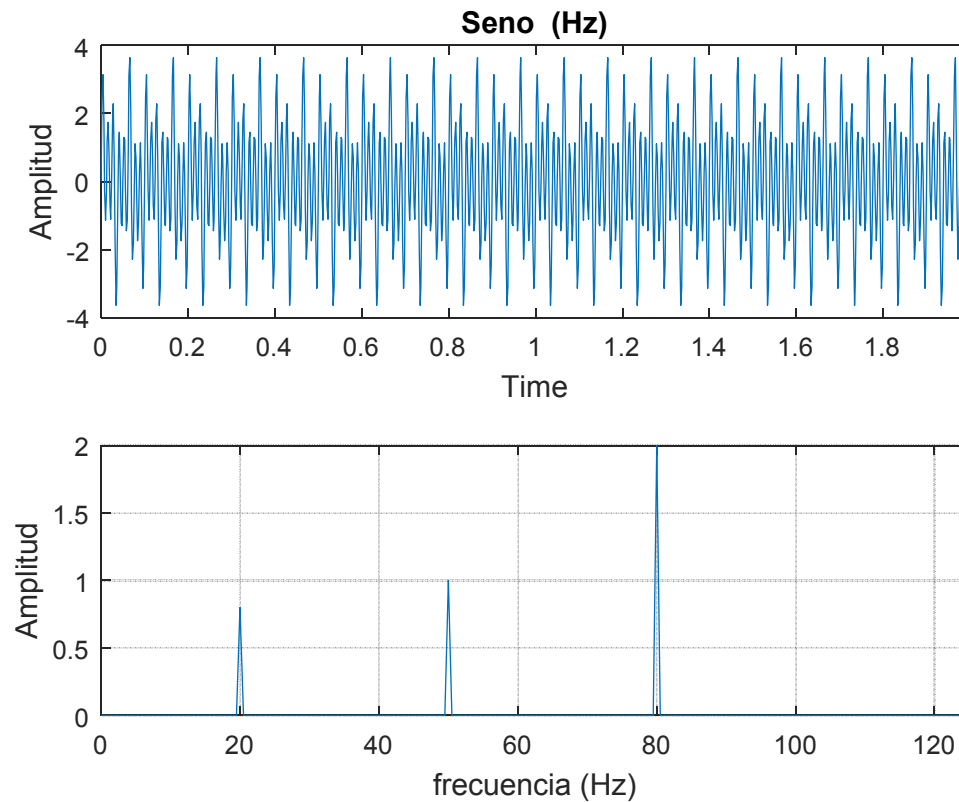
## Ejemplo: DFT de Seno

$$f(t) = \sin(2\pi 40t), \quad F_s = 300 \left( \frac{\text{muestras}}{\text{sec}} \right)$$




## Ejemplo: DFT de Seno

$$f(t) = 0.8 \sin(2\pi 20t) + \sin(2\pi 50t) + \sin(2\pi 80t), \quad F_s = 500 \left( \frac{\text{muestras}}{\text{sec}} \right)$$



## Ejemplo: DFT de Seno

$$f(t) = 0.8\sin(2\pi 20t) + \sin(2\pi 50t) + \sin(2\pi 80t) + n(t), \quad F_s = 500 \left( \frac{\text{muestras}}{\text{sec}} \right)$$







## Entropía Espectral de Shannon

- Sea  $X$  una serie de tiempo  $=\{x_1, x_2, \dots, x_N\}$ .
- La Entropía Espectral es calculada como:

$$H(X) = -\frac{1}{\log_2(N)} \sum_{k=1}^N P(x_k) \log_2(P(x_k))$$

$$P(x_k) = \frac{A_k^2}{\sum_{k=1}^N A_k^2}$$

$$A_k = \left| \sum_{n=1}^N x_n \exp\left(-j2\pi \times \frac{k \times n}{N}\right) \right|$$



# Red Neuronal Superficial (SNN)


**Algoritmo de Aprendizaje:**


**miniBatch RMSprop**

**+**

**miniBatch Adam**

# SNN





# SNN

**Algoritmo de Aprendizaje:  
miniBatch RMSprop**



## Training de SNN: miniBatch RMSprop

- Considerar una base de datos de  $N$ -muestras dada como:

$$\{X_i, Y_i\}_{i=1}^N, \quad X_i \in \mathbb{R}^d, \quad Y_i \in \mathbb{R}^m$$

- $X_i$  : representa la data de training
- $Y_i$  : representa la data deseada



## miniBatch RMSprop: Etapas del Algoritmo

- **Paso 1:** Re-ordenar aleatoriamente la localización de cada muestra de la base de datos de training.
- **Paso 2:** Dividir las  $N$ -muestras de datos en Batch de  $M$ -muestras.

$$T = \frac{N}{M}$$

$T$  : Número de Batch

- **Paso 3:** Entrenar la SNN usando un Número Máximo de Épocas.
  - Cada Épocas ajusta los pesos de la SNN  $T$ -veces vía el RMSProp.

# Algoritmo Aprendizaje: miniBatch RMSprop

**Costo: MSE**

$$E = \frac{1}{2M} \sum_{n=1}^M C_n = \frac{1}{2M} \sum_{n=1}^M \sum_{k=1}^{n_L} \left( a_{k,n}^{(L)} - d_{k,n} \right)^2$$

**Activación Capa Salida:**

$$a^{(L)} = f(a^{(L-1)})$$

**Activación Capas Ocultas:**

$$a^{(l)} = g(a^{(l-1)}), l = 1, 2, \dots, L-1$$

- **M: número de muestras ,  $n_L$ : nodos de salidas,  $d_{k,n}$ : valor deseado**
- **$f(\cdot)$ : función de activación Capa de Salida**
- **$g(\cdot)$ : función de activación Capas Ocultas**

## Ajuste Pesos de Salida: miniBatch RMSprop

**Pesos de Salida:**

$$W^{(L)}(t) = W^{(L)}(t-1) - \mu \times gRMS$$
$$\mu \in (0,1), t = 1, \dots, T$$

**Notación Matricial:  
Actualización Pesos Salida**

$$gRMS = \frac{1}{\sqrt{V^{(L)}(t) + \varepsilon}} \otimes gW^{(L)}$$
$$V^{(L)}(t) = \beta \times V^{(L)}(t-1) + (1 - \beta) \times (gW^{(L)})^2$$

**Notación Matricial:  
Gradiente**

$$gW^{(L)} = \delta^{(L)} \times (a^{(L-1)})^T$$
$$\delta^{(L)} = e^{(L)} \otimes f'(z^{(L)})$$

**Valores Iniciales:**

$$\beta = 0.9, \varepsilon \in (10^{-6}, 10^{-10})$$
$$V^{(L)} = W^{(L)}.shape$$
$$V^{(L)}(0) = 0$$



# Ajuste Pesos Ocultos: SNN+RMSprop

**Pesos de Ocultos:**

$$W^{(l)}(t) = W^{(l)}(t-1) - \mu \times gRMS$$

**Notación Matricial:  
Actualización Pesos Ocultos**


$$gRMS = \frac{1}{\sqrt{V^{(l)}(t) + \varepsilon}} \otimes gW^{(l)}$$
$$V^{(l)}(t) = \beta \times V^{(l)}(t-1) + (1 - \beta) \times (gW^{(l)})^2$$

**Notación Matricial:  
Gradiente**

$$gW^{(l)} = \left\{ \left( w^{(l+1)} \right)^T \times \delta^{(l+1)} \right\} \otimes g'(z^{(l)}) \times \left( a^{(l-1)} \right)^T$$
$$l = L-1, L-2, \dots, 3, 2, 1$$

**Valores Iniciales:**

$$\beta = 0.9, \varepsilon \in (10^{-6}, 10^{-10})$$
$$V^{(l)} = W^{(l)}.shape, \quad l = 1, 2, \dots, L-1$$
$$V^{(l)}(0) = 0$$



**Red Neuronal Superficial (SNN):**

**Algoritmo de Aprendizaje miniBatch Adam**



## Algoritmo Aprendizaje: miniBatch Adam

**Costo:**  
**Entropía cruzada**

$$E = -\frac{1}{M} \sum_{n=1}^M \sum_{k=1}^{n_L} d_{k,n} \log(a_{k,n}^{(L)})$$

$N$  = Número muestras

$n_L$  = Nodos de salidas

$d_{k,n}$  = Valor deseado de la clase  $k$ .

**Activación Capa Salida:**

$$a_n^{(L)} = \frac{z^{(L)}(:, n)}{\sum_{k=1}^{n_L} z_{k,n}^{(L)}}, \quad n = 1, \dots, M$$

$$z^{(L)} = \exp(w^{(L)} \times a^{(L-1)}), \quad z^{(L)} \in \Re^{(n_L \times M)}, w^{(L)} \in \Re^{(n_L \times n_{L-1})}$$

**Activación Capas Ocultas:**

$$a^{(l)} = g(a^{(l-1)}), \\ l = L-1, L-2, \dots, 1$$



# Algorithm Aprendizaje: miniBatch Adam

## Actualización Pesos de Salida

$$w^{(L)}(t) = w^{(L)}(t-1) - \mu \times gAdam$$

$$t = 1, 2, \dots, MaxIter$$

$$\mu \in (0, 1)$$

## Algorithm Aprendizaje: miniBatch Adam

### Actualización Pesos de Salida

$$gAdam = \frac{\sqrt{1 - \beta_2^t}}{1 - \beta_1^t} \times \frac{V^{(L)}(t)}{\sqrt{S^{(L)}(t) + \varepsilon}}, \quad \varepsilon = (10^{-6}, 10^{-8})$$

$$V^{(L)}(t) = \beta_1 \times V^{(L)}(t-1) + (1 - \beta_1) \frac{\partial E}{\partial w^{(L)}(t-1)}$$
$$S^{(L)}(t) = \beta_2 \times S^{(L)}(t-1) + (1 - \beta_2) \left( \frac{\partial E}{\partial w^{(L)}(t-1)} \right)^2$$

$$w^{(L)}(0) = \text{random}$$
$$V^{(L)}(0), S^{(L)}(0) = W^{(L)}.shape$$
$$V^{(L)}(0), S^{(L)}(0) = 0$$
$$\beta_1 = 0.9 \quad \beta_2 = 0.999$$



## Algoritmo Aprendizaje: miniBatch Adam


### Actualización Pesos Ocultos

$$w^{(l)}(t) = w^{(l)}(t-1) - \mu \times gAdam$$

$$l = L-1, L-2, \dots, 2, 1$$

$$t = 1, 2, \dots, MaxIter$$

$$\mu \in (0, 1)$$




## Algorithm Aprendizaje: miniBatch Adam

### Actualización Pesos Ocultos

$$gAdam = \frac{\sqrt{1 - \beta_2^t}}{1 - \beta_1^t} \times \frac{V^{(l)}(t)}{\sqrt{S^{(l)}(t) + \varepsilon}}$$

$$V^{(l)}(t) = \beta_1 V^{(l)}(t-1) + (1 - \beta_1) \frac{\partial E}{\partial w^{(l)}(t-1)}$$
$$S^{(l)}(t) = \beta_2 S^{(l)}(t-1) + (1 - \beta_2) \left( \frac{\partial E}{\partial w^{(l)}(t-1)} \right)^2$$


$$w^{(l)}(0) = \text{random}, \quad l = 1, 2, \dots, L - 1$$
$$V^{(l)}(0), S^{(l)}(0) = w^{(l)}.shape$$
$$V^{(l)}(0), S^{(l)}(0) = 0$$
$$\beta_1 = 0.9 \quad \beta_2 = 0.999$$



## TAREA 3 :

**Descomposición de Hankel**  
+  
**SNN+RMSprop + Adam**





# **Funciones de Activación:**



## Función de Activación

- 1. ReLu:

$$f(x) = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases}, x \in \mathbb{R}^d$$

- 2. L-ReLu:

$$f(x) = \begin{cases} 0.01x, & x < 0 \\ x, & x \geq 0 \end{cases}, x \in \mathbb{R}^d$$

- 3. ELU:

$$f(x) = \begin{cases} a(e^x - 1), & x \leq 0 \\ x, & x > 0 \end{cases}, x \in \mathbb{R}^d$$

- 4. SELU:

$$f(x) = \lambda \times \begin{cases} a(e^x - 1), & x \leq 0 \\ x, & x > 0 \end{cases}$$

$x \in \mathbb{R}^d, \lambda = 1.0507, a = 1.6732$



## Función de Activación

- 5. C-ReLU:

$$f(x) = \max(0, x) + \cos(x), \quad x \in \mathbb{R}^d$$

- 6. S-ReLU:

$$f(x) = \max(0, x) + \sin(x), \quad x \in \mathbb{R}^d$$

- 7. Tangente Hiperbólica (tanh):

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}, \quad x \in \mathbb{R}^d$$



## Función de Activación

- 8. mTanh:


$$f(x) = a \times \tanh(bx), \quad x \in \mathbb{R}^d$$
$$a = 1.7159, \quad b = \frac{2}{3}$$

- 9. Bipolar sigmoid:

$$f(x) = \frac{2}{1 + e^{-x}} - 1, \quad x \in \mathbb{R}^d$$

- 10. Softsign:

$$f(x) = \frac{x}{1 + |x|}, \quad x \in \mathbb{R}^d$$



## Función de Activación

- 11.- Softplus:

$$f(x) = \log(1 + e^x), \quad x \in \mathbb{R}^d$$

- 12.- Sigmoid Linear Unit:

$$f(x) = \frac{x}{1 + e^{-x}}, \quad x \in \mathbb{R}^d$$



CONTINUARÁ....